

Testes realizados nos modelos de detecção: Yolo, Faster Rcnm e SSD.

- Para fazer a detecção e rotulagem em 5000 imagens retiradas do nosso dataset para medir a eficiência de cada modelo.
- Foram consideradas as métricas de desempenho: Média de tempo gasta por imagem, Tempo total gasto e Total de imagens não detectadas.

Testes realizados no modelos pré-treinados na base de dados do Singapore Maritime Dataset:

Modelos yolo:

- Full_Yolo_v2_smd
- Tiny_Yolo_v2_smd
- Squeezenet_Yolo_v2_smd
- Full_Yolo_v2_smd_2

Dataset 1 - O código extrai cada primeiro quadro de cada vídeo do SMD, com os primeiros 70% para treinamento e os 30% restantes para testes.

Dataset 2 - Mesma divisão, porém os quadros de 4 vídeos selecionados são adicionados completamente na parte de teste.

Dataset		Média de tempo gasta por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Modelos Faster_RCNN e SSD:
1	Full_yolo_v2	0.486	40.51	
	tiny_yolo_v2	0.148	12.34	
	squeezenet_yolo_v2	0.07510	6.25	
2	full_yolo_v2_2	0.45	37.51	

- Faster_rcnn_inception_v2
- Faster_rcnn_resnet101
- Faster_rcnn_resnet50
- Ssd_inception_v2
- Ssd_mobilenet_v1
- Ssd_mobilenet_v2
- Ssd_resnet50_v1
- Faster_rcnn_inception_v2_2
- Faster_rcnn_resnet50_2
- Ssd_mobilenet_v1_2

- **Threshold = 0.99**

		Média de tempo gasta por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Total de imagens não detectadas
Dataset 1	Faster_rcnn_inception_v2	7.60	633.54	423
	Faster_rcnn_resnet101	5.17	431.45	321
	Faster_rcnn_resnet50	10.37	864.34	342
	Ssd_inception_v2	2.53	211	3798
	Ssd_mobilenet_v1	3.26	272.45	4625
	Ssd_mobilenet_v2	2.20	183.91	4419
	Ssd_resnet50_v1	6.70	558.76	4809
Dataset 2	Faster_rcnn_inception_v2_2	2.13	178.29	416
	Faster_rcnn_resnet50_2	3.44	287.41	275
	Ssd_mobilenet_v1_2	3.90	325.38	4560

- **Threshold = 0.4 (Dataset 1)**

	Média de tempo gasta por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Total de imagens não detectadas
Faster_rcnn_inception_v2	8.69	724.82	19
Faster_rcnn_resnet101	9.99	832.8	12
Faster_rcnn_resnet50	3.46	288.89	15
Ssd_inception_v2	3.34	278	553
Ssd_mobilenet_v1	2.99	249.59	88
Ssd_mobilenet_v2	1.33	110.95	1009
Ssd_resnet50_v1	7.14	595.71	183

- **Threshold = 0.1**

		Média de tempo gasta por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Total de imagens não detectadas	Acurácia (%)
Dataset 1	Faster_rcnn_inception_v2	2.05	170.84	4	56.18%
	Faster_rcnn_resnet101	4.80	400.75	0	68.92%
	Faster_rcnn_resnet50	3.47	289.68	2	79.12%
	Ssd_inception_v2	2.26	189.01	80	86.34%
	Ssd_mobilenet_v1	2.89	241.07	0	
	Ssd_mobilenet_v2	1.30	108.77	253	80.0%
	Ssd_resnet50_v1	4.64	387.45	0	
Dataset 2	Faster_rcnn_inception_v2_2	2.16	180.62	5	61.54%
	Faster_rcnn_resnet50_2	3.56	297.40	1	51.24%
	Ssd_mobilenet_v1_2	2.89	241.07	0	

*Acurácia obtida através de análise e descarte das imagens rotuladas erroneamente

- **Threshold = 0.6 (Dataset 1)**

	Média de tempo gasta por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Total de imagens não detectadas
Faster_rcnn_inception_v2	2.99	249.59	41
Faster_rcnn_resnet101			
Faster_rcnn_resnet50	3.50	291.83	25
Ssd_inception_v2	3.34	278.39	939
Ssd_mobilenet_v1			
Ssd_mobilenet_v2	1.23	103.10	1660
Ssd_resnet50_v1			

Transferência de aprendizado:

- Testes realizados utilizando transferência de aprendizado com cinco modelos:
 - InceptionV3
 - MobileNetV2
 - ResNet50V2
 - ResNet152V2
 - VGG19
- Treinamento para classificação de barcos em um banco de dados de 6240 imagens.
- Identificação e classificação de Navios (5 classes):
- Cargo, Carrier, Cruise, Military, Tanker.

- InceptionV3

- Acurácia de 73.28%.



- MobileNetV2

- Acurácia de 73.76%.



- ResNet50V2

- Acurácia de 76.33%.



- ResNet152V2

- Acurácia de 77.27%.



- VGG19

- Acurácia de 78.24%.



Modelos de Segmentação

- Os modelos Mask R_CNN e PointRend_Resnet50 são pré-treinados no conjunto de dados Microsoft Coco, com 80 categorias de objetos comuns.

Teste:

- O objetivo do teste foi encontrar outras possíveis alternativas para a rotulagem semi-automática, que possam ter melhor desempenho e fazermos uma comparação entre elas.
- Testes realizados nas mesmas 5000 imagens dos modelos de Singapura apresentados na reunião passada.
- Com o parâmetro confidence = 0.7.
- Apenas para a classe de barcos.
- A acurácia foi determinada pelo mesmo método que os modelos de Singapura.

$$Acc = \frac{\text{segmentação não satisfatória} + \text{imagens não segmentadas}}{\text{número de imagens total}}$$

	Média de tempo gasto por imagem (s)	Tempo Total gasto em 5000 imagens (min)	Acurácia
Mask_rcnn	0.75	62.55	96,2%

Pointrend_resnet50

2.78

231.98

93.24%

Notebooks no github:

[Sinagapore-Maritime](#)

Generico_Singapura.ipynb: notebook que roda os modelos de Singapura, salva as imagens com as detecções e salva os .txt com as coordenadas da localização do objeto. Ele também exclui os arquivos txt sem nenhuma detecção (vazios) e salva as imagens sem detecção em outra pasta, para controle.

Gray_Exclude.ipynb: Move as imagens em preto e branco de uma pasta para outra. Alguns modelos não rodam em imagens preto e branco, por isso separá-las.

Video_to_photo.ipynb: Gera frames de vídeos como imagens jpg.

[Segmentation](#)

Segmentation.ipynb: notebook que roda os modelos de segmentação utilizando a biblioteca pixellib

[data-conversion](#)

Nesta pasta se encontram vários notebooks úteis para conversão das anotações para outros formatos.